Методы глубокого обучения и актуальные задачи биоинформатики

***Дюкова Елена Всеволодовна*[1]** edjukova@mail.ru

[1] Москва, ФИЦ ИУ РАН

***Пестов Иван Алексеевич*[2]** qwark777@gmail.com

[2] МГУ имени М. В. Ломоносова

16-я Международная конференция «Интеллектуализация обработки информации» (ИОИ-2026)

Intelligent Data Processing: Theory and Applications, IDP-2026

Беларусь, г. Витебск, 28 сентября – 2 октября 2026 г.

Постановка задачи распознавания промотеров

Drosophila melanogaster

положительные примеры
участки промотеров

отрицательные примеры
участки экзонов

задача бинарной классификации

Распознавание промотеров (gene promoter prediction)

Для оценки качества классификации используется ROC-AUC.

Логическая классификация и корректные ЭК

Каждый признак имеет ограниченное множество допустимых значений, которые кодируются целыми числами.

Обучение классификатора сводится к поиску в исходных данных информативных фрагментов описаний прецедентов — корректных элементарных классификаторов.

Искомые ЭК позволяют различать объекты из разных классов и имеют содержательное описание в терминах прикладной области.

Понятие представительного ЭК класса K

Представительный ЭК класса K — ДК (допустимая конъюнкция) B(σ,H) для функции F_k.

$H = \{x_{j1}, \ldots, x_{jr}\}$, $\sigma = (\sigma_1, \ldots, \sigma_r)$, где σ_i — допустимое значение x_{ji}.

$B = x_{j1}^{\sigma 1} \wedge \ldots \wedge x_{jr}^{\sigma r}$

описания прецедентов класса K	**описания прецедентов других классов**
$F_k = 1$	**$F_k = 0$**

По определению интервал истинности ДК:

- имеет непустое пересечение с множеством единиц функции F_k;
- имеет пустое пересечение с множеством нулей функции F_k.

Если описание объекта S принадлежит интервалу истинности B, то объект S содержит ЭК B.

Вычислительные ограничения

Из-за требования корректности на этапе обучения возникают сложные в вычислительном плане дискретные задачи.

В случае многозначных признаков для повышения точности классификации применяется корректная перекодировка данных, что приводит к дополнительным вычислительным затратам.

Предыдущие результаты для Drosophila melanogaster

Статья: «Распознавание особых участков генома методами машинного обучения»

Классификатор	k-меры	прямое применение
REC	**0,904**	**0,943**
Catboost	**0,948**	**0,951**

Наилучший результат: Catboost — ROC-AUC 0,951

При прямом применении из-за низкой значности признаков качество REC существенно выше: ROC-AUC 0,943.

Алгоритмы СЛ, ЛР и LightGB тестировались только с традиционной методикой и существенно уступили Catboost.

Логическая нейросеть LAD_NN

Статья: «Logical Data Analysis and Classification: Traditional and Neural Network Approaches»

Принцип работы LAD_NN

1. Для каждого класса K строится отдельная нейронная сеть.
2. Вход задаётся системой булевых уравнений; их левые части представлены конъюнктивными нормальными формами.
3. На этапе обучения сеть ищет максимальную совместную подсистему уравнений. Логические блоки аппроксимируют дизъюнкцию, конъюнкцию и отрицание.
4. Максимальные логические закономерности класса K — представительные ЭК, содержащиеся в наибольшем числе прецедентов этого класса. По ним выполняется классификация.

LAD_NN

На реальных данных из репозитория UCI LAD_NN сравнивалась с MLP и сверточной сетью. Показано качество, сопоставимое с традиционными нейросетевыми подходами.

Цель работы

Статья: «Распознавание особых участков генома методами машинного обучения»

MLP **LAD_NN**

Две методики формирования признакового пространства

способ 1
k-меры

способ 2
прямое применение к исходной выборке

k-мер — подстрока длины k в символьной последовательности ДНК.

показатель качества классификации: ROC-AUC

Результаты экспериментов (способ 1 формирования признакового пространства)

Формирование признакового пространства: k-меры

Нейросеть	базовая	с подбором гиперпараметров
MLP	**0,950**	**0,963**
LAD_NN	**0,857**	**0,910**

Подбор гиперпараметров важен как для MLP, так и для LAD_NN.

MLP: 0,950 → 0,963 LAD_NN: 0,857 → 0,910

Результаты экспериментов (способ 2 формирования признакового пространства)

Прямое применение к исходной выборке

MLP с подбором гиперпараметров

ROC-AUC = 0,970

LAD_NN с подбором гиперпараметров

ROC-AUC = 0,964

Наилучший результат: MLP — 0,970

Аналогичный показатель для LAD_NN равен 0,964.

Сводные результаты

Нейросеть	Формирование признакового пространства	ROC-AUC
MLP (базовая)	способ 1	**0,950**
LAD_NN (базовая)	способ 1	**0,857**
MLP (с подбором гиперпараметров)	способ 1	**0,963**
LAD_NN (с подбором гиперпараметров)	способ 1	**0,910**
MLP (с подбором гиперпараметров)	способ 2	**0,970**
LAD_NN (с подбором гиперпараметров)	способ 2	**0,964**

Логическая нейросеть так же, как и классические логические классификаторы, показывает более высокое качество, когда признаки имеют низкую значность.

Заключение

• Прямое применение к исходной выборке дает лучшие результаты для обеих нейросетей.
• Подбор гиперпараметров повышает качество MLP и LAD_NN.
• LAD_NN сохраняет связь с логическим подходом и показывает качество, сопоставимое с MLP.

Перспективное направление для дальнейших исследований в задачах биоинформатики

Благодарю за внимание