Методы глубокого обучения и актуальные задачи биоинформатики

Дюкова Елена Всеволодовна[1] edjukova@mail.ru
Пестов Иван Алексеевич[2]⋆ qwark777@gmail.com
[1]Москва, ФИЦ ИУ РАН
[2]МГУ имени М.В. Ломоносова

Исследуются вопросы применения нейросетевого подхода к задачам логического анализа и классификации больших данных. Рассматривается важная и сложная задача биоинформатики, заключающаяся в распознавании особых структурных сегментов геномов, называемых промотерами (англ.: gene promoter prediction).

При конструировании логических классификаторов большое внимание уделяется вопросам синтеза корректных алгоритмов, т.е. алгоритмов, не ошибающихся на обучающей выборке. Предполагается, что каждый признак имеет ограниченное множество допустимых значений, которые кодируются целыми числами. Как правило, обучение классификатора сводится к поиску в исходных данных информативных фрагментов описаний прецедентов, называемых корректными элементарными классификаторами (ЭК). Искомые ЭК позволяют различать объекты из разных классов и имеют содержательное описание в терминах той прикладной области, в которой решается задача. По их наличию в описании распознаваемого объекта решается вопрос о его классификации. Однако из-за требования корректности классификатора на этапе обучения возникают сложные в вычислительном плане дискретные задачи. В случае многозначных признаков для повышения точности классификации применяется корректная перекодировка данных, что приводит к дополнительным вычислительным затратам. Фундаментальная роль в создании рассматриваемого подхода к задаче классификации принадлежит научным школам чл.-корр. РАН С. В. Яблонского и акад. РАН Ю. И. Журавлёва.

Главным образом рассматриваются модели логических классификаторов, основанные на поиске ЭК специального вида, называемых представительными ЭК. Представительный ЭК класса K — это допустимая конъюнкция (ДК) для не всюду определённой двузначной логической функции F_K, принимающей на целочисленных описаниях прецедентов класса K и других классов соответственно значение 1 и 0. По определению интервал истинности ДК функции F_K имеет непустое пересечение с множеством единиц функции F_K и пустое пересечение с множеством нулей этой функции.

Для решения задачи распознавания промотера в [1] впервые применены методы машинного обучения, основанные на логическом анализе и классификации данных. С использованием модельного организма Drosophila melanogaster, являющегося одним из наиболее распространенных модельных организмов в биоинформатике, решалась задача бинарной классификации. В качестве поло-

жительных примеров брались участки промотеров, а отрицательные примеры представляли собой участки экзонов. На несбалансированной выборке большого объёма проведены эксперименты, в которых участвовали такие известные алгоритмы машинного обучения, как случайный лес (СЛ), логистическая регрессия (ЛР) и различные модели градиентного бустинга (LightGB, Catboost, XGBoost), а также «быстрый» логический классификатор, именуемый алгоритмом голосования по правильным представительным элементарным классификаторам (REC) [2]. Был рассмотрен традиционный способ формирования признаков, использующий k-меры, и оригинальная методика прямого применения классификатора к исходным символьным последовательностям промотеров и экзонов. Оказалось, что во втором случае из-за низкой значности признаков качество логической классификации существенно выше и составляет с использованием ансамблевого подхода 0,943 по показателю ROC-AUC. Сравнимое качество у классификатора XGBoost. Наилучший результат, а именно, точность по ROC-AUC, равную 0,951, показал классификатор Catboost при прямом применении к исходной выборке. Таким образом, логический классификатор REC незначительно уступил классификатору Catboost. Алгоритмы СЛ, ЛР и LightGB тестировались с применением только традиционной методики и существенно уступили Catboost. При формировании признаков на основе k-мер показатели точности Catboost и REC соответственно равны 0,948 и 0,904.

Следует отметить, что из-за временных ограничений при тестировании классификатора REC в [1] проводилась предварительная обработка данных с целью «корректного» снижения значности исходных целочисленных значений признаков. Для уменьшения времени счёта первоначальное число признаков было сокращено до 150 за счёт выделения наиболее информативных признаков на основе анализа информативности их отдельных значений.

В [3] предложен подход, объединяющий методы логической классификации с возможностями нейросетевого анализа данных. Построена и исследована логическая нейросеть LAD_NN, архитектура которой включает специализированные нейросетевые блоки, аппроксимирующие базовые булевы операции дизъюнкцию, конъюнкцию и отрицание. Каждому классу K соответствует своя нейронная сеть. Классификация проводилась на основе поиска так называемых максимальных логических закономерностей класса K, то есть ДК функции F_K, принимающих значение 1 на наибольшем числе описаний прецедентов. Использовалась методика, согласно которой искомый поиск сводится к задаче нахождения решений максимальной совместной подсистемы системы логических уравнений. На реальных данных из репозитория UCI (`https://archive.ics.uci.edu/`) проведено сравнение LAD_NN с двумя классическими нейросетями, а именно многослойным перцептроном (MLP) и сверточной сетью. Показано, что логико-нейронная архитектура демонстрирует качество, сопоставимое с традиционными нейросетевыми подходами.

В настоящей работе задача gene promoter prediction решалась с применением нейронных сетей MLP и LAD_NN на тех же данных, что и в статье [1]. Также, как и в [1], рассматривались две методики формирования признакового пространства: первый (традиционный) способ, использующий k-меры и второй способ, заключающийся в прямом применении к исходной выборке. Для оценки качества классификации применялся показатель ROC-AUC. Результаты счёта приведены в табл. 1.

Таблица 1. Показатели качества классификаторов.

Нейросеть	Формирование признакового пространства	ROC-AUC
MLP (базовая)	способ 1	0,950
LNN (базовая)	способ 1	0,857
MLP (с подбором гиперпараметров)	способ 1	0,963
LNN (с подбором гиперпараметров)	способ 1	0,910
MLP (с подбором гиперпараметров)	способ 2	0,970
LNN (с подбором гиперпараметров)	способ 2	0,964

Нетрудно видеть, что наилучший результат, равный 0,970, был получен для MLP при использовании второго способа формирования признакового пространства и подбора гиперпараметров. Аналогичный показатель для LAD_NN равен 0,964.

Таким образом, подтверждено, что методика формирования признакового пространства существенно влияет на качество классификации. Кроме того, подбор гиперпараметров оказался важным как для MLP, так и для LAD_NN. Логико-нейронный подход показал качество, сопоставимое с MLP, что делает его перспективным направлением для дальнейших исследований в задачах биоинформатики.

[1] *Дюкова Е. В., Дюкова А. П.* Распознавание особых участков генома методами машинного обучения // Искусственный интеллект и принятие решений. — 2024. — № 4. — С. 95–104.

[2] *Драгунов Н. А., Дюкова Е. В., Дюкова А. П.* Логическая классификация на основе поиска правильных представительных элементарных классификаторов // Известия РАН. Теория и системы управления. — 2024, № 4. — С. 86–92.

[3] *Anisimova D. V., Djukova E. V., Pestov I. A.* Logical Data Analysis and Classification: Traditional and Neural Network Approaches // Pattern Recognition and Image Analysis. Advances in Mathematical Theory and Applications. — 2026. — Vol. 36, № 2. — Pp. 729–737.